

1 Popište možné tvary dynamických systémů pro modely: spojité-diskrétní, lineární-nelineární.

Lineární spojité systém v časové oblasti

$$\begin{aligned}\dot{\mathbf{x}} &= \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} \\ \mathbf{y} &= \mathbf{C}\mathbf{x} + \mathbf{D}\mathbf{u}\end{aligned}$$

Lineární spojité systém ve frekvenční oblasti

$$\begin{aligned}s\mathbf{x} &= \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} \\ \mathbf{y} &= \mathbf{C}\mathbf{x} + \mathbf{D}\mathbf{u}\end{aligned}$$

Po úpravě $\mathbf{x}(s\mathbf{I} - \mathbf{A}) = \mathbf{B}\mathbf{u}$ můžeme dosadit

$$\mathbf{y} = \mathbf{C}(s\mathbf{I} - \mathbf{A})^{-1}\mathbf{B}\mathbf{u} + \mathbf{D}\mathbf{u} \quad (1)$$

Dynamická poddajnost

$$\mathbf{G}(x) = \frac{\mathbf{y}}{\mathbf{u}} = \mathbf{C}(s\mathbf{I} - \mathbf{A})^{-1}\mathbf{B} + \mathbf{D} \quad (2)$$

Lineární diskrétní systém

$$\begin{aligned}\mathbf{x}_{t+\Delta t} &= \mathbf{M}\mathbf{x}_t + \mathbf{N}\mathbf{u}_t \\ \mathbf{y}_t &= \mathbf{O}\mathbf{x}_t + \mathbf{P}\mathbf{u}_t\end{aligned}$$

diskrétní tvar lze získat z tvaru spojitého modelu v časové oblasti

$$\mathbf{M} = e^{\mathbf{A}\Delta t}, \mathbf{N} = (e^{\mathbf{A}\Delta t} - \mathbf{I})\mathbf{B}\mathbf{A}^{-1}, \mathbf{O} = \mathbf{C}, \mathbf{P} = \mathbf{D}$$

Nelineární systém

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}) + \mathbf{g}(\mathbf{x})\mathbf{u} \quad (3)$$

$$\mathbf{y} = \mathbf{c}(\mathbf{x}) + \mathbf{d}(\mathbf{x})\mathbf{u} \quad (4)$$

2 Popište postup identifikace lineárního modelu SISO systému ve tvaru ARX a OE.

2.1 Auto Regresive model with eXogenous inputs

Lineární filtr používající minulé vstupy a výstupy systému

$$\hat{y}(t) + a_1 y(t - \Delta t) + \dots + a_n y(t - n\Delta t) = b_0 u(t) + \dots + b_n u(t - n\Delta t) \quad (5)$$

Pro N kroků měření lze vypsát $N - n$ rovnic

$$\begin{aligned} \hat{y}_n &= -a_1 y_{n-1} - \dots - a_n y_0 + b_0 u_n + \dots + b_n u_0 \\ &\vdots \\ \hat{y}_N &= -a_1 y_{N-1} - \dots - a_n y_{N-n} + b_0 u_N + \dots + b_n u_{N-n} \end{aligned}$$

Ty lze zapsat ve tvaru

$$\hat{\mathbf{y}} = \Phi \mathbf{p}, \quad (6)$$

kde

$$\begin{aligned} \hat{\mathbf{y}} &= \begin{bmatrix} \hat{y}_n & \dots & \hat{y}_N \end{bmatrix}^T \\ \Phi &= \begin{bmatrix} y_{n-1} & \dots & y_0 & u_n & \dots & u_0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ y_{N-1} & \dots & y_{N-n} & u_N & \dots & u_{N-n} \end{bmatrix} \\ \mathbf{p} &= \begin{bmatrix} -a_1 & \dots & -a_n & b_0 & \dots & b_n \end{bmatrix}^T \end{aligned}$$

2.2 Output Error model

Lineární filtr používající minulé vstupy a výstupy modelu

$$\hat{y}(t) + a_1 \hat{y}(t - \Delta t) + \dots + a_n \hat{y}(t - n\Delta t) = b_0 u(t) + \dots + b_n u(t - n\Delta t) \quad (7)$$

zbytek obdobně jako pro ARX jen se změnou y na \hat{y} .

3 Popište postup identifikace lineárního modelu SISO systému ve tvaru FIR.

$$\hat{y}(t) = g_0 u(t) + g_1 u(t - \Delta t) + \dots + g_n u(t - n\Delta t) \quad (8)$$

$$\hat{y}_n = g_0 u_n + g_1 u_{n-1} + \dots + g_n u_0 \quad (9)$$

$$\vdots \quad (10)$$

$$\hat{y}_N = g_0 u_N + g_1 u_{N-1} + \dots + g_n u_{N-n} \quad (11)$$

$$\hat{\mathbf{y}} = \Phi \mathbf{p}, \quad (12)$$

kde

$$\begin{aligned}\hat{\mathbf{y}} &= \begin{bmatrix} \hat{y}_n & \dots & \hat{y}_N \end{bmatrix}^T \\ \Phi &= \begin{bmatrix} u_n & \dots & u_0 \\ \vdots & \ddots & \vdots \\ u_N & \dots & u_{N-n} \end{bmatrix} \\ \mathbf{p} &= \begin{bmatrix} g_0 & \dots & g_n \end{bmatrix}^T\end{aligned}$$

4 Vysvětlete jak se sestavují Markovovy parametry a Hankelovy matice pro diskrétní stavový model.

$$\mathbf{x}_1 = \mathbf{B}\mathbf{u}_0 \qquad \mathbf{y}_0 = \mathbf{D}\mathbf{u}_0 \qquad (13)$$

$$\mathbf{x}_2 = \mathbf{A}\mathbf{B}\mathbf{u}_0 + \mathbf{B}\mathbf{u}_1 \qquad \mathbf{y}_1 = \mathbf{C}\mathbf{x}_1 + \mathbf{D}\mathbf{u}_1 = \mathbf{C}\mathbf{B}\mathbf{u}_0 + \mathbf{D}\mathbf{u}_1 \qquad (14)$$

$$\mathbf{x}_{k+1} = \sum_{i=0}^k \mathbf{A}^{k-i} \mathbf{B}\mathbf{u}_i \qquad \mathbf{y}_k = \sum_{i=1}^k \underbrace{\mathbf{C}\mathbf{A}^{k-i}\mathbf{B}}_{h_i} \mathbf{u}_i + \underbrace{\mathbf{D}}_{h_0} \mathbf{u}_k \qquad (15)$$

$$\mathbf{Y} = \mathbf{H}\mathbf{U} \qquad (16)$$

kde \mathbf{Y} je matice tvořena výstupy, \mathbf{U} matice vstupů a matice \mathbf{H} je Hankelova matice či matice *Markovových parametrů*. q je voleno dle času ustálení impulzní odezvy tak, aby $\mathbf{y}_q \approx \mathbf{0}$.

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_0 & \mathbf{y}_0 & \dots & \mathbf{y}_q \end{bmatrix} \qquad (17)$$

$$\mathbf{U} = \begin{bmatrix} \mathbf{u}_0 & \mathbf{u}_1 & \dots & \mathbf{u}_q \\ \mathbf{0} & \mathbf{u}_0 & \dots & \mathbf{u}_{q-1} \\ \vdots & & & \vdots \\ \mathbf{0} & \dots & & \mathbf{u}_{q-p} \end{bmatrix} \qquad (18)$$

$$\mathbf{H} = \begin{bmatrix} h_0 & h_1 & \dots & h_p \end{bmatrix} \qquad (19)$$

4.1 Hankelovy matice

$$\mathbf{H}_1 = \begin{bmatrix} h_1 & h_2 & \dots & h_p \\ h_2 & h_3 & \dots & h_{p+1} \\ \vdots & \vdots & & \vdots \\ h_p & h_{p+1} & \dots & h_{2p-1} \end{bmatrix}, \quad \mathbf{H}_2 = \begin{bmatrix} h_2 & h_3 & \dots & h_{p+1} \\ h_3 & h_4 & \dots & h_{p+2} \\ \vdots & \vdots & & \vdots \\ h_{p+1} & h_{p+2} & \dots & h_{2p} \end{bmatrix} \qquad (20)$$

5 Popište identifikaci diskrétního stavového modelu pomocí metody ERA při znalosti Hankelových matic a Markovových parametrů. Co je to balancovaný tvar modelu ?

Hanklovy matice H_1 a H_2 lze zapsat jako

$$H_1 = PQ, \quad H_2 = PAQ \quad (21)$$

kde P je matice pozorovatelnosti a Q matice říditelnosti.

Balancovaný tvar zajistíme SVD rozkladem H_1 na

$$H_1 = V\Gamma^2U^T \Rightarrow P = V\Gamma, \quad Q = \Gamma U^T \quad (22)$$

Matice identifikovaného systému pak jsou

$$A = P^+ H_2 Q^+ \quad (23)$$

$$B = Q[:, 1 : s] \quad (24)$$

$$C = P[1 : r, :] \quad (25)$$

kde s je počet vstupů, r počet výstupů a P^+ , Q^+ pseudo-inverze, které lze získat přímo z SVD rozkladu

$$P^+ = \Gamma^{-1}V^T, \quad Q^+ = U\Gamma^{-1} \quad (26)$$

6 Vysvětlete rozdíl mezi modelem MDOF tlumeného mechanického systému s viskózním a strukturním tlumením. V čem je model se strukturním tlumením problematický pro časovou simulaci ?

Pohybové rovnice systému buzeného harmonickou funkcí

- s viskózním tlumením

$$M\ddot{x} + B\dot{x} + Kx = F \quad (27)$$

- se strukturním tlumením

$$M\ddot{x} + (jH + K)x = F \quad (28)$$

Strukturní model tlumení se speciálně orientovaný na analýzu ve frekvenční oblasti, jelikož v časové oblasti zanáší do simulace komplexní čísla.

Ve frekvenční oblasti $B\omega = H$

7 Popište modální transformaci mechanického systému, vysvětlete pojem proporcionálního tlumení.

Pro systém ve tvaru

$$M\ddot{x} + C\dot{x} + Kx = F$$

je základem modální transformace nalezení řešení zobecněného problému vlastních čísel

$$KV = \Omega^2 MV$$

kde ϕ_i jsou vlastní vektory a Ω_i vlastní frekvence tvořící matice V a Ω

$$V = \begin{bmatrix} \phi_1 & \dots & \phi_N \end{bmatrix}, \quad \Omega^2 = \text{diag}(\Omega_i^2), \quad i \in \langle 1, N \rangle$$

Pro navzájem ortogonální vlastní vektory s vahou matice hmotnosti (získané příslušnou normalizací) platí

$$V^T M V = I, \quad V^T K V = \Omega^2$$

lze zavedením modální souřadnic q , $x = Vq$ a vynásobením transponovanou maticí modální transformace V^T zleva, převést do tvaru

$$\ddot{q} + \Gamma \dot{q} + \Omega^2 q = V^T F, \quad \Omega = V^T K V, \quad \Gamma = V^T B V$$

O systému můžeme říct, že má proporční tlumení, je-li matice C lineární kombinací matic M a K . Pak je tato matice diagonalizovatelná modální transformací V a matice Γ je diagonální s prvky $(\Gamma)_{ii} = 2\zeta_i \Omega_i$, kde ζ_i jsou poměrné útlumy. Soustava se pak rozpadá na samostatně řešitelné rovnice ve tvaru

$$\ddot{q}_i + 2\Omega_i \zeta_i \dot{q}_i + \Omega_i^2 q_i = f_i, \quad f_i = \phi_i \cdot F, \quad i \in \langle 1, N \rangle$$

8 Napište a vysvětlete MAC kritérium pro porovnání vlastních tvarů modelu a vlastních tvarů naměřených.

Modal Assurance Criterion

$$M_{rq} = \frac{(\phi_{A_r}^T \phi_{X_r})^2}{(\phi_{A_r}^T \phi_{A_r})(\phi_{X_r}^T \phi_{X_r})}, \quad r = 1, \dots, n, \quad q = 1, \dots, m \quad (29)$$

kde n a m je počet módů, ϕ_{A_r} měřené vlastní vektory a ϕ_{X_r} vlastní vektory modelu.

MAC kritérium se užívá pro zhodnocení shody vlastních vektorů modelu a měřeného systému. Při dokonalé shodě $M = I$.

9 Popište metodu SDOF identifikace mechanického systému z naměřených přenosových funkcí.

Tato metoda je použitelná pouze pro lineární identifikaci. Často v kombinaci s *chirp* buzením. Výhoda reprezentace dat ve frekvenční oblasti je hustota informace a relativně nízká míra její ztráty oproti časové oblasti, kde mohou být data uložena pouze jako série diskrétních datových bodů [Matlab].

10 Popište princip LSCF metody MDOF identifikace mechanického systému z naměřených přenosových funkcí. K čemu slouží stabilizační diagram ?

Least Squares Complex Frequency domain estimator

$$\mathbf{G}(s) = \frac{\mathbf{B}(s)}{\mathbf{A}(s)} \quad (30)$$


kde

$$\mathbf{B} = \begin{bmatrix} B_{11}(s) & B_{12}(s) & \dots & B_{1N_i}(s) \\ B_{21}(s) & B_{22}(s) & \dots & B_{2N_i}(s) \\ \vdots & \vdots & \ddots & \vdots \\ B_{N_o1}(s) & B_{N_o2}(s) & \dots & B_{N_oN_i}(s) \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} A_{11}(s) & A_{12}(s) & \dots & A_{1N_i}(s) \\ A_{21}(s) & A_{22}(s) & \dots & A_{2N_i}(s) \\ \vdots & \vdots & \ddots & \vdots \\ A_{N_o1}(s) & A_{N_o2}(s) & \dots & A_{N_oN_i}(s) \end{bmatrix} \quad (31)$$

a

$$B_{ii} = \sum_{j=0}^m b_{ii_j} s^j, \quad A_{ii} = \sum_{j=0}^n a_{ii_j} s^j \quad (32)$$

Stabilizační diagram slouží k identifikaci fyzikálních pólů, které se nemění při postupném zvyšování řádu modelu.





Obrázek 1: Stabilizační diagram

11 Co je nelineární model Hammersteinova typu a nelineární model Wienerova typu.

Modely skládající se z dynamického lineárního přenosu $G(q)$ a statické nelineární funkce f

Model Hammersteinova typu





Model Weinerova typu

12 Uveďte strukturu nelineární identifikace používající koncept LOLI-MOT.

Local Linear Models Tree

The main idea is to approximate a generally nonlinear multivariable function describing a dynamic system output with the scalar product of the vector of linear functions of the system inputs and the vector of so-called validity functions.

$$\hat{y} = \sum_{i=1}^M \hat{y}_i(\mathbf{x}) \phi_i(\mathbf{z}) \quad (33)$$

kde \hat{y}_i jsou *lokální lineární modely*

$$\hat{y}_i = w_{i0} + w_{i1}x_1 + w_{i2}x_2 + \dots + w_{in}x_n \quad (34)$$

a $\phi_i(u)$ jejich platnostní funkce, formulovány jako normalizované ortogonální Gaussovské rozdělení, které splňují

$$\sum_{i=1}^n \phi_i(u) = 1, \quad \phi_i(u) = \frac{\mu_i(u)}{\sum_{i=1}^n \mu_i(u)}, \quad \mu_i = \exp \left(-\frac{1}{2} \sum_{j=1}^M \frac{(u_j - c_{ij})^2}{\sigma_{ij}^2} \right) \quad (35)$$

kde M je počet LLM a c_{ij} a σ_{ij}^2 , která jsou volitelná, jsou popořadě střední hodnota a rozptyl i -tého rozdělení pro j -tý LLM. Vektory zobecněných vstupů, neboli *regresorů*, \mathbf{x} a \mathbf{z} obecně obsahují okamžité vstupy systému $u_j(k)$, minulé vstupy systému $u_j(k-r)$ a minulé výstupy systému $y(k-s)$, kde r a s jsou horizonty závislosti na vstupech a výstupech, popořadě. \mathbf{z} je nazýván vektor premis (premises) a \mathbf{x} vektor konsekventů (consequents).

- Vnitřní cyklus: výpočet koeficientů w_i LLM při daném rozložení platnostních funkcí (exaktní - LSQ)
- Vnější cyklus: hledání vhodného "rozdělení" oblasti (heuristika)

13 Uveďte postup identifikace nelineárního diskrétního dynamického modelu LOLIMOT typu NARX.

LOLIMOT typu NARX (Nonlinear Auto Regressive with Exogenous inputs) se liší od modelu v otázce 12 pouze ve tvaru lokálních modelů, který lze obecně zapsat jako

$$\hat{y}_k = f(u_k, u_{k-1}, \dots, y_{k-1}, y_{k-2}, \dots) \quad (36)$$

a způsobu jejich identifikace.

14 Vysvětlete pojmy testování a trénování identifikovaného modelu.

Trénování

Při trénování jsou parametry identifikovaného modelu upravovány tak, aby chování systému co nejvíce odpovídalo *trénovacím datům*.

Testování

Při testování porovnáváme chování identifikovaného modelu k nové sadě *testovacích dat*, abychom ověřili, že nedošlo k přetrénování modelu, tzn. přizpůsobení ke konkrétním trénovacím datům, nikoliv obecnému chování.

15 Vysvětlete rozdíl mezi simulačním a predikčním trénováním a použitím LOLIMOT modelu a souvislost těchto pojmů s NARX a NOE modely.

Simulační trénování

Identifikovaný model je odpojený od reálného systému a pracuje pouze s jeho vstupy, kde chyba výstupu se kumuluje.

Odpovídá schématu NOE (Nonlinear Output Error)

$$\hat{y}_k = f(u_k, u_{k-1}, \dots, \hat{y}_{k-1}, \hat{y}_{k-2}, \dots) \quad (37)$$

Predikční trénování

Model je připojen k výstupům modelu reálného systému

Odpovídá schématu NARX

$$\hat{y}_k = f(u_k, u_{k-1}, \dots, y_{k-1}, y_{k-2}, \dots) \quad (38)$$

- 16 Uved'te příklad identifikace ad-hoc sestaveného dynamického modelu soustavy s pomocí obecných optimalizačních metod.
- 17 Uved'te základní postup identifikace fyzikálního modelu získaného např. z MKP po transformaci do redukováného modálního tvaru. V čem tato redukce usnadní postup identifikace ?

Na základě naměřených/navržených vlastností materiálu vytvořím mkp model ve tvaru

$$M\ddot{x} + C\dot{x} + Kx = F$$

Ten následně transformuju do modálních souřadnic


$$I\ddot{q} + \Gamma\dot{q} + \Omega^2q = V^T F, \quad \Omega = V^T K V, \quad \Gamma = V^T B V$$

a oříznu mimodiagonální prvky transformované matice tlumení Γ , přičemž prvky na diagonále lze vyjádřit jako $\beta_{ii} = 2b_{r_i}\Omega_i$. Dále můžu provést redukci, odstraněním tvarů odpovídajících vyšším frekvencím systému.

Výsledkem je model závislý pouze na parametrech ω_i, b_{r_i} pro každý zanechaný tvar, které můžu dále optimalizovat. Oproti black-box identifikaci nehrozí vznik umělých artefaktů.


- 18 Uved'te příklad využití fenomenologického identifikovaného modelu pro simulaci.

Fenomenologicky například inentifikujeme tření nebo nelineární chování tlumiče.



Obrázek 2: Coulomb

- 19 Popište použití identifikovaného modelu soustavy v regulátoru s prediktivním řízením. Jak souvisí s pojmy NARX a NOE modelů ?



Obrázek 3: Stribeck